Ein Leitfaden für Anfänger zu Anomalieerkennungstechniken in der Datenwissenschaft

In diesem Artikel gebe ich Ihnen eine kurze Einführung in die Anomalieerkennung und führe Sie durch die verschiedenen Techniken, mit denen Sie Anomalien identifizieren können.

Von Eugenia Anello , KDnuggets am 17. Mai 2023 in Data Science

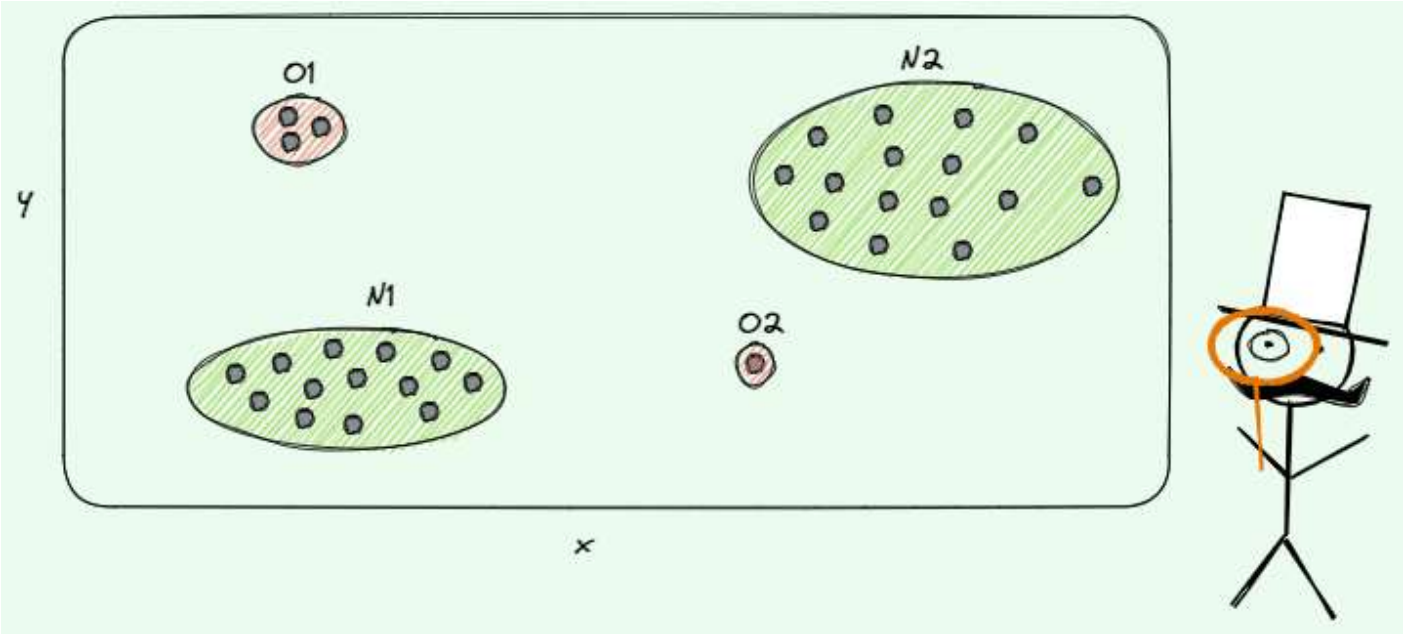

Bild vom Autor

Die Erkennung von Anomalien ist eine sehr wichtige Aufgabe, die Sie erfüllen können oder in Zukunft erfüllen werden, wenn Sie mit Daten arbeiten. Es wird in vielen Bereichen eingesetzt, beispielsweise in der Fertigung, im Finanzwesen und in der Cybersicherheit.

Der erste Einstieg in dieses Thema kann ohne einen Leitfaden, der Sie Schritt für Schritt anleitet, eine Herausforderung sein. Ich erinnere mich, dass ich bei meiner ersten Erfahrung als Datenwissenschaftler große Schwierigkeiten hatte, diese Disziplin zu meistern.

Bei der Anomalieerkennung geht es zunächst darum, seltene Beobachtungen zu identifizieren, deren Werte drastisch von den übrigen Datenpunkten abweichen. Diese Anomalien, die oft als Ausreißer bezeichnet werden, sind eine Minderheit, während die meisten Elemente zur normalen Klasse gehören. Das bedeutet, dass wir es mit einem unausgeglichenen Datensatz zu tun haben.

Eine weitere Herausforderung besteht darin, dass bei der Arbeit in der Branche meist keine gekennzeichneten Daten vorliegen und es schwierig ist, die Vorhersagen ohne Ziel zu interpretieren. Das bedeutet, dass Sie keine Bewertungsmetriken verwenden können, die normalerweise für Klassifizierungsmodelle verwendet werden, und dass Sie andere Methoden anwenden müssen, um die Ausgabe Ihres Modells zu interpretieren und ihr zu vertrauen. Lass uns anfangen!

Was ist Anomalieerkennung?

Unter Anomalieerkennung versteht man das Problem, Muster in Daten zu finden, die nicht dem erwarteten Verhalten entsprechen. Diese nicht konformen Muster werden in verschiedenen Anwendungsbereichen häufig als Anomalien, Ausreißer, nicht übereinstimmende Beobachtungen, Ausnahmen, Aberrationen, Überraschungen, Besonderheiten oder Kontaminanten bezeichnet. Erkennung von Kreditanomalien : Eine Umfrage

Dies ist eine gute Definition der Anomalieerkennung in wenigen Worten. Anomalien sind oft mit Fehlern bei der Datenerfassung verbunden und müssen dann behoben werden. Es gibt aber auch Fälle, in denen es neue Items mit einer völlig anderen Variabilität im Vergleich zum Rest der Daten gibt und Bedarf an geeigneten Ansätzen besteht, um diese Art von Beobachtung zu erkennen. Die Identifizierung dieser Beobachtungen kann für die Entscheidungsfindung in Unternehmen, die in vielen Sektoren tätig sind, beispielsweise im Finanz- und Fertigungsbereich, sehr nützlich sein.

Welche Arten von Anomalien gibt es?

Es gibt drei Haupttypen von Anomalien: Punktanomalien, kontextbezogene Anomalien und kollektive Anomalien.

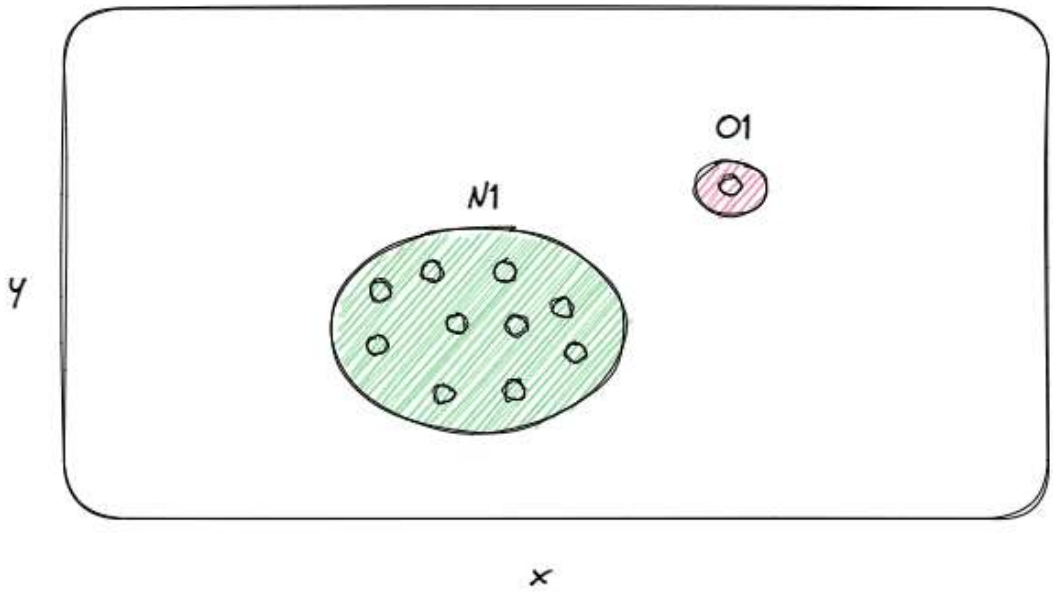

Beispiel einer Punktanomalie. Illustration vom Autor.

Wie Sie vielleicht ableiten, stellen **Punktanomalien** den einfachsten Fall dar. Dies geschieht, wenn eine einzelne Beobachtung im Vergleich zu den übrigen Daten anomal ist und daher als Ausreißer/Anomalie identifiziert wird. Nehmen wir zum Beispiel an, dass wir die Erkennung von Kreditkartenbetrug bei den Transaktionen von Kunden in einer Bank ermöglichen möchten. In diesem Fall kann eine Punkteanomalie als betrügerische Aktivität eines Kunden angesehen werden.

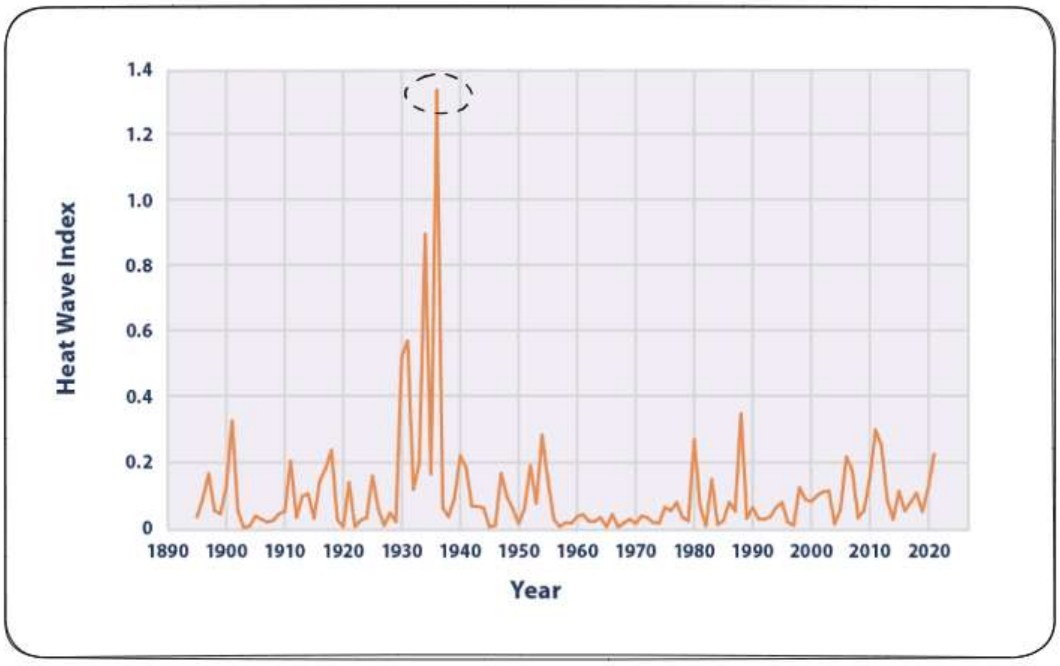

Beispiel einer kontextuellen Anomalie. Kredit -EPA . Vom Autor geändert.

Ein weiterer Fall einer Anomalie kann eine **kontextbezogene Anomalie** sein . Diese Art von Anomalie kann nur in einem bestimmten Kontext auftreten. Ein Beispiel können die sommerlichen Hitzewellen in den Vereinigten Staaten sein. Sie können feststellen, dass es im Jahr 1930 einen enormen Anstieg gab, der ein extremes Ereignis darstellt, das sich in den Vereinigten Staaten ereignete und als Dust Bowl bezeichnet wurde. Es wird so genannt, weil es eine Zeit voller Staubstürme war, die den Süden der Vereinigten Staaten verwüsteten.

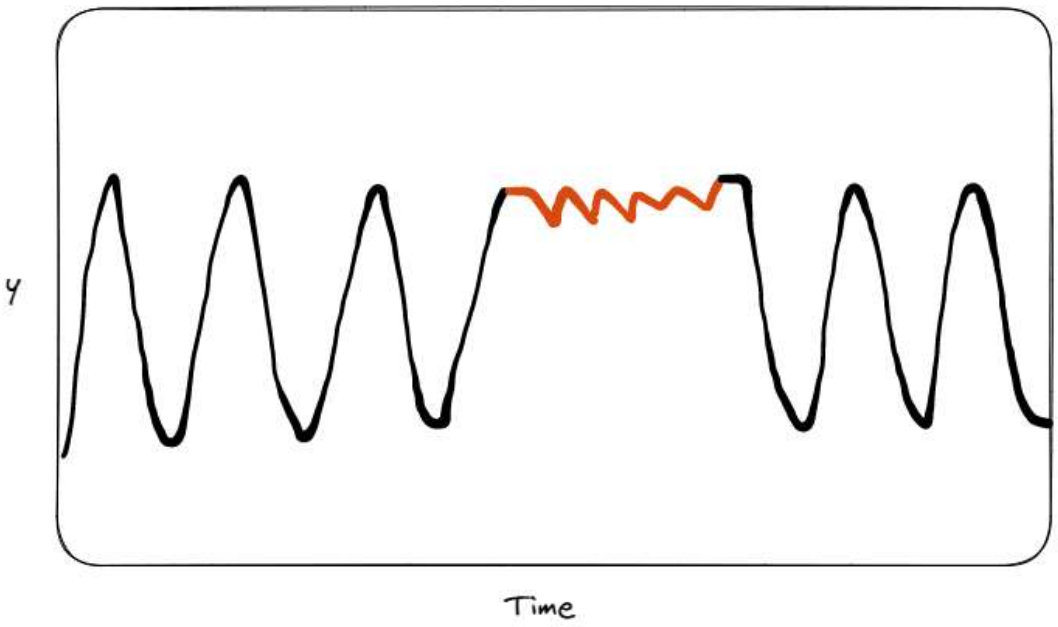

Beispiel einer kollektiven Anomalie. Illustration vom Autor.

Die dritte und letzte Anomalieart ist die **kollektive Anomalie** . Das intuitivste Beispiel ist, wenn man an die Abwesenheit von Niederschlägen denkt, die wir dieses Jahr seit Monaten in Italien haben. Wenn wir die Daten der letzten 50 Jahre vergleichen, gab es noch nie ein ähnliches Verhalten. Die einzelnen Dateninstanzen in einem anomalen Kollektiv können für sich genommen möglicherweise nicht als Ausreißer identifiziert werden, aber alle diese Datenpunkte zusammen weisen auf eine kollektive Anomalie hin. In diesem Zusammenhang ist ein einzelner Tag ohne Niederschlag an sich keine Anomalie, während viele Tage ohne Niederschlag im Vergleich zu den Daten früherer Jahre als Anomalie angesehen werden können.

Welche Modelle des maschinellen Lernens können zur Anomalieerkennung verwendet werden?

Es gibt verschiedene Ansätze, die zur Anomalieerkennung angewendet werden können:

1. **Isolation Forest** ist eine unbeaufsichtigte und nichtparametrische Technik, die 2012 von Fey Tony Liu eingeführt wurde. Wie der Random Forest handelt es sich um eine Ensemble-Lernmethode, die Entscheidungsbäume parallel trainiert. Anders als andere Ensemble-Methoden ist sie jedoch darauf spezialisiert, die Anomalien vom Rest der Elemente zu isolieren. Die diesem Ansatz zugrunde liegenden Annahmen stellen den Grund für die Wirksamkeit dieses Ansatzes dar: (1) Die Anomalien gehören zu einer Minderheitsklasse im Vergleich zu den normalen Daten, die zahlreicher sind; (2) Die Anomalien werden tendenziell schnell mit dem kürzesten Durchschnittsweg gefunden.
2. **Local Outlier Factor** ist ein von Markus M. Breuning im Jahr 2000 vorgeschlagener dichtebasierter Clustering-Algorithmus, der Anomalien erkennt, indem er die lokale

Dichteabweichung eines bestimmten Elements in Bezug auf seine Nachbarn berechnet. Dabei wird davon ausgegangen, dass sich die Dichte um eine Anomalie deutlich von der Dichte um ihre Nachbarn unterscheiden sollte. Darüber hinaus sollten die Ausreißer eine geringere Dichte aufweisen.

3. **Autoencoder** ist ein unbeaufsichtigtes Modell, das aus zwei neuronalen Netzen besteht, einem Encoder und einem Decoder. Während des Trainings werden nur normale Daten an das Modell übergeben. Auf diese Weise lernt es die komprimierte Darstellung normaler Daten, die sich von der Darstellung von Ausreißern unterscheiden soll. Es besteht auch die Annahme, dass anomale Daten vom Modell nicht gut rekonstruiert werden sollten, da sie sich völlig von normalen Daten unterscheiden und daher einen höheren Rekonstruktionsfehler aufweisen sollten.

Wie kann ich ein Anomalieerkennungsmodell in einer unbeaufsichtigten Umgebung evaluieren?

In einer unbeaufsichtigten Umgebung gibt es keine Bewertungsmetriken, die Ihnen helfen können, die Rate korrekter positiver Vorhersagen (Präzision) oder die Rate tatsächlich positiver Ergebnisse (Erinnerung) zu verstehen.

Ohne die Möglichkeit, die Leistung des Modells zu bewerten, ist es wichtiger denn je, eine Erklärung für Modellvorhersagen bereitzustellen. Dies kann durch die Verwendung von Interpretierbarkeitsansätzen wie SHAP und LIME erreicht werden.

Es gibt zwei mögliche Interpretationen: global und lokal. Das Ziel der globalen Interpretierbarkeit besteht darin, Erklärungen für das Modell als Ganzes bereitzustellen, während die lokale Interpretierbarkeit darauf abzielt, die Modellvorhersage einer einzelnen Instanz zu erklären.

Abschließende Gedanken

Ich hoffe, dass dieser kurze Überblick über die Techniken zur Anomalieerkennung für Sie hilfreich war. Wie Sie bemerkt haben, handelt es sich um ein schwierig zu lösendes Problem, und die geeignete Technik variiert je nach Kontext. Ich sollte auch betonen, dass es wichtig ist, vor der Anwendung eines Anomalieerkennungsmodells eine explorative Analyse durchzuführen, wie z. B. PCA zur Visualisierung der Daten in einem niedrigerdimensionalen Raum und Boxplots. Wenn Sie tiefer gehen möchten, sehen Sie sich die folgenden Ressourcen an. Danke fürs Lesen! Einen schönen Tag noch!

Ressourcen

- Anomalieerkennung: Eine Umfrage von V. Chandola
- Artikel von Isolation Forest
- Paper Review: Rekonstruktion durch Inpainting zur visuellen Anomalieerkennung
- SHAPs Papier
- LIMEs Artikel

Eugenia Anello ist derzeit wissenschaftliche Mitarbeiterin am Institut für Informationstechnik der Universität Padua, Italien. Ihr Forschungsprojekt konzentriert sich auf kontinuierliches Lernen in Kombination mit Anomalieerkennung.

Mehr zu diesem Thema

- Automatisierte Anomalieerkennung mit PyCaret
- So nutzen Sie maschinelles Lernen zur Anomalieerkennung und bedingten…
- Ein Leitfaden für Anfänger zum Q-Learning
- Ein Anfängerleitfaden zum CLIP-Modell
- Ein Leitfaden für Anfänger zum durchgängigen maschinellen Lernen
- Ein Leitfaden für Anfänger zum Web Scraping mit Python